

AURORA INFINITY

Intelligence Artificielle Souveraine & Edge Computing

LIVRE BLANC — VERSION PUBLIQUE

Porteur de Projet	C.B.R.
Statut du Document	Version Publique — Dépôt GitHub
Version Système	Aurora V5.4 — Neuro Engine 04/06/2026
Environnement de Développement	Ryzen 5 3600 32 Go DDR4-3600 NVMe 500 Go RTX 2060 6 Go
Localisation	Île de La Réunion — France
Date	Juin 2026

Ce document est une présentation technique et conceptuelle ouverte du projet Aurora Infinity, destinée au dépôt GitHub officiel et à la communauté open-source. Les détails d'implémentation sensibles font l'objet d'une documentation séparée à accès restreint.



1. Introduction — Genèse du Projet

Aurora Infinity est né d'une frustration fondamentale : la perte systématique de l'information. Des centaines d'heures de veille, des vidéos, des articles, des données disparates — sans structure, sans mémoire persistante. Cette impuissance face au flux informationnel a été le moteur premier de l'architecture Aurora.

Ce qui a débuté comme un script de chiffrement et d'archivage sur mobile s'est progressivement transformé en un moteur cognitif complet. L'évolution s'est faite en trois ères distinctes :

Ère 1 — L'Ancrage : Stocker et Protéger

Les premières versions mobiles avaient un objectif simple et impérieux : sécuriser la donnée. Aurora fonctionnait comme un gardien numérique — chiffrement AES rigoureux, arborescence hiérarchique de N0 à N17. L'information ne devait plus se perdre.

Ère 2 — L'Éveil Analytique : Comprendre

La migration vers une architecture PC marque le passage du coffre-fort au bibliothécaire. Intégration du bilinguisme français/anglais, analyse de dominance linguistique, filtrage sémantique. Aurora commençait à se regarder lui-même — journaux d'acquisition, mesure de la densité du savoir.

Ère 3 — Le Système Expert Hybride : Raisonner

L'intégration de PyTorch, FAISS et des moteurs LLM locaux via Ollama a fait muter le système. Aurora projette désormais ses connaissances dans un espace multidimensionnel, analyse par calcul symbolique et spectral, surveille sa propre santé matérielle, et génère des synthèses complexes via architecture RAG. Ce n'est plus un programme — c'est une interface de calcul souveraine.

2. Proposition de Valeur Unique

« Le futur de l'IA n'est pas dans le cloud. Il est local, souverain, et il travaille pour vous — pas pour des serveurs tiers. »

Aurora Infinity apporte une réponse concrète à l'un des défis numériques les plus critiques : exploiter la puissance des grands modèles de langage (LLM) tout en garantissant l'étanchéité absolue des données. L'architecture repose sur trois piliers :

Pilier 1 — Un Outil, Mille Métiers

Le cœur algorithmique s'adapte instantanément aux connaissances injectées sans modification du code. La même infrastructure peut agir en expert juridique, en assistant de diagnostic médical, ou en moteur de synthèse scientifique — selon la base documentaire fournie.

Pilier 2 — La Souveraineté Absolue

L'exécution est 100 % locale (on-premise / Air-Gapped). Aucune donnée ne transite par des serveurs externes. La propriété intellectuelle reste dans les murs de l'organisation. Cette architecture est particulièrement critique pour les secteurs soumis au RGPD, au secret professionnel (droit, médecine), et aux contraintes HDS.

Pilier 3 — L'Indépendance Totale

Suppression des abonnements cloud récurrents et de la facturation aux tokens. Résilience technique absolue : le système fonctionne sans connexion internet. Atout stratégique crucial pour les territoires ultramarins comme La Réunion, exposés aux coupures de câbles sous-marins.

3. Architecture Technique

3.1 Vue Globale du Moteur

Le moteur Aurora Infinity s'articule autour de deux modules principaux fonctionnant en circuit totalement fermé :

Pipeline Vectoriel de Masse

Extraction et transformation des textes bruts (.pdf, .docx, .txt) en vecteurs denses stockés dans un index topologique local géré par FAISS. Les requêtes s'exécutent sur des centaines de milliers de mots en moins de deux secondes. Le corpus actuel du moteur dépasse 8 000 neurones avec 4 000 points de rendu et 3 962 synapses actives.

Oracle Anti-Hallucination

Les segments extraits de la base locale sont injectés de façon sécurisée dans un LLM compact exécuté en localhost via l'API Ollama. Une ingénierie de prompt stricte interdit au modèle d'extrapoler — il ne répond qu'à partir des faits documentés fournis. Zéro hallucination par conception architecturale.

3.2 Commandes Système — Console Interactive

Aurora expose une console interactive avec un catalogue de commandes logiques. Voici les commandes principales telles que déployées dans la version V5.4 :

Commande	Description
injection	Séquence maîtresse 4 étapes : (1) Assimilation .txt+.pdf, (2) Clean, (3) Defrag, (4) Purge finale — ingestion totale dans le corpus vectoriel
oracle	Interrogation vectorielle guidée par le contexte RAG — Système Expert avec base documentaire FAISS

matrice	Extraction ACP 3D et projection spatiale des poids de la couche W1 — visualisation 3D des clusters de connaissances via PyVista
calcul	Module Calcul — Calcul symbolique exact via SymPy (ex: <code>diff(x**2, x)</code>)
fourier	Module Calcul — Analyse spectrale FFT d'un signal pour identification des fréquences dominantes
executer	Module Calcul — Exécution autonome de code Python dans un bac à sable sécurisé
forge	Module Forge — Génération de scripts Python structurée via le LLM local (Ollama)
scout	Agent Scout — Recherche PDF en tâche de fond via Docker
clean	Purge des adresses mémoire redondantes, condensateurs et caches CUDA
defrag	Consolidation sémantique et réalignement du dictionnaire (Mode Manuel)
maint	Maintenance fusionnée : Clean + Defrag en séquence automatique
pruning	MOD-4 — Élagage synaptique dynamique, suppression des poids sous-seuil
turbo	Commutation de l'état de performance logiciel
verifier	Interrogation brute des APIs os, psutil et nvml
equation	Affichage des équations matricielles de transformation
stats	Rapport d'allocation des structures de données
securite	Vérification d'intégrité de la clé de hachage de configuration
quitter	Protocole d'interruption, sauvegarde binaire et fermeture des threads

3.3 Infrastructure Matérielle Actuelle (Environnement R&D)

Le développement et la validation de l'architecture Aurora V5.4 ont été intégralement réalisés sur la station de travail suivante, démontrant la frugalité algorithmique et l'agnosticisme matériel du système :

Composant	Spécification
Processeur	AMD Ryzen 5 3600 (6 cœurs / 12 threads — Architecture Zen 2)
Mémoire Vive	32 Go DDR4-3600 MHz
Stockage	NVMe SSD 500 Go
GPU	NVIDIA RTX 2060 — 6 Go VRAM
Système	Windows 11 — Environnement natif
LLM Local	Ollama (qwen2.5:3b) — Exécution offline complète
Modules IA	FAISS actif PDF actif (pypdf) GUARD/SAUVER/PERF/CORE : ACT
Corpus Actuel	8 000 neurones 4 000 rendus ~3 962 synapses calculées

Preuve de concept critique : L'intégralité des capacités documentées dans ce livre blanc — réseau neuronal 3D, oracle RAG, pipeline vectoriel, calcul symbolique, analyse spectrale — est opérationnelle sur cette configuration matérielle grand public. La contrainte des 6 Go de VRAM est le seul goulot d'étranglement identifié.

4. Modules Fonctionnels Avancés

4.1 Réseau Neuronal 3D — Visualisation PyVista

La commande 'matrice' déclenche une Analyse en Composantes Principales (ACP) 3D des poids de la couche W1. Le résultat est une projection spatiale dynamique du réseau de connaissances, rendu en temps réel via PyVista. Sur la configuration actuelle :

- Matrice W1 : 129 686 lignes — Échantillon PCA : 8 000 (6.2%)
- Variance expliquée : PC1=7.0%, PC2=2.7%, PC3=2.0%
- Corpus : 8 000 neurones — Rendu : 4 000 (50%)
- Synapses calculées sur 2 000 points

La visualisation révèle la topologie réelle du savoir stocké — les clusters de connaissances apparaissent comme des constellations de neurones interconnectés dans l'espace 3D.

4.2 Calcul Symbolique & Spectral

Le module CALCUL intègre trois outils complémentaires :

- SymPy : Calcul symbolique exact — dérivées, intégrales, simplifications algébriques
- FFT (Fast Fourier Transform) : Décomposition spectrale de signaux temporels pour identifier les fréquences dominantes
- Exécution Python Autonome : Bac à sable sécurisé pour l'exécution de code généré ou fourni

4.3 Système d'Archivage Rhizome

Aurora maintient un registre système persistant nommé 'Rhizome' — une boîte noire horodatée de toutes les opérations. Ce journal traçable inclut :

- Chaque document assimilé avec métadonnées de session
- Les opérations de maintenance et leurs métriques
- Les interactions oracle avec les contextes fournis
- Les événements de sécurité et vérifications d'intégrité

Le fichier RHIZOME_DATA constitue la mémoire institutionnelle du système — archivé vers F:/RHIZOME_DATA/Archives après chaque opération majeure. Les tests en cours incluent l'assimilation de corpus philosophiques, scientifiques et techniques (Méditations de Marc Aurèle, traités de physique quantique, documentation industrielle).

4.4 Catégorisation Sémantique Automatique

Le pipeline d'injection réalise une ventilation automatique de chaque document en fragments catégorisés selon la taxonomie interne :

Catégorie	Domaine
CAT_0_Base	Connaissances fondamentales — fondations du corpus
CAT_1_Psycho	Psychologie — comportement, cognition, émotions
CAT_2_Science	Sciences — physique, mathématiques, biologie
CAT_3_Outils	Outils techniques — méthodes, frameworks, protocoles
CAT_4_Expertise	Expertise métier — domaines spécialisés injectés

5. Verrous Technologiques Levés

5.1 Réécriture Matricielle à Chaud

Aurora lève l'obligation de réentraînement lourd grâce à une mise à jour incrémentale asynchrone des tenseurs en mémoire vive (RAM/VRAM). L'opérateur ajoute des documents à la volée — le système recalcule l'espace vectoriel instantanément, sans redémarrage ni interruption de service. Cette approche de 'matrix hot-rewriting' est un différenciateur technique majeur face aux solutions LLM classiques qui nécessitent des cycles de fine-tuning coûteux.

5.2 Agnosticisme Matériel & Green IT

Conçu dans une démarche de Green IT, Aurora intègre un nettoyage agressif des caches CUDA et une gestion optimisée de la VRAM. Le système est pleinement fonctionnel sur une RTX 2060 6 Go — matériel grand public de milieu de gamme — démontrant qu'une IA souveraine avancée n'est pas l'apanage exclusif des data centers.

5.3 Élagage Synaptique Dynamique (MOD-4 Pruning)

La commande 'pruning' implémente un algorithme d'élagage synaptique qui supprime dynamiquement les poids sous-seuil du réseau neuronal. Cette optimisation réduit l'empreinte mémoire et améliore la vitesse d'inférence sans dégradation mesurable de la qualité des réponses.

6. Protocoles de Sécurité — Phase R&D en Cours

 Les fonctionnalités de sécurité décrites dans cette section sont en cours de

développement et de validation. Elles constituent des objectifs de R&D formellement définis, pas encore déployés en production.

La protection des données de recherche exige une architecture où la sécurité physique du matériel est aussi absolue que la sécurité logicielle. Deux niveaux de protection sont en cours d'implémentation :

6.1 Niveau 1 — Chiffrement AES-256 du Corpus (Objectif R&D)

Objectif : Chiffrement intégral de l'ensemble des disques de stockage hébergeant le noyau Aurora et les modules de recherche selon le standard militaire AES-256. Une fois la machine hors tension, les données constituent un amas cryptographique indéchiffrable. Toute tentative d'extraction physique des disques sera rendue inutile.

Périmètre de chiffrement planifié :

- Le cerveau synaptique (tenseurs de poids neuronaux de la couche W1)
- Les index vectoriels FAISS
- Le registre Rhizome (journal système)
- Les corpus documentaires injectés

6.2 Niveau 2 — Télémétrie d'Urgence Anti-Vol (Objectif R&D)

Objectif : En cas de vol physique de la station, si l'équipement est démarré et connecté à un réseau, le micro-noyau déclenche une routine silencieuse. Dès détection d'un accès internet, la machine établit automatiquement un pont de télémétrie chiffré vers le serveur central, transmettant adresse IP, logs de routage et coordonnées de localisation.

6.3 Traçabilité Utilisateur (Objectif R&D)

Développement d'un système de logs complets horodatés pour chaque commande, indexant obligatoirement un code personnel d'identification propre à chaque utilisateur. Ce mécanisme assure l'auditabilité complète du système en contexte multi-utilisateurs.

6.4 Ce qui est Opérationnel Aujourd'hui

Dans la version actuelle V5.4, la sécurité repose sur :

- Vérification d'intégrité de la clé de hachage de configuration (commande 'securite')
- Sauvegarde binaire automatique avant fermeture des threads (commande 'quitter')
- Architecture Air-Gapped native — aucune donnée ne transite par l'extérieur lors de l'exécution standard
- Isolation du bac à sable d'exécution Python

7. Domaines d'Application Stratégiques

7.1 Secteur Juridique & Conformité

Les cabinets d'avocats et études notariales manipulent des volumes massifs de textes protégés par le secret professionnel. Aurora permet :

- Analyse de jurisprudence interne sur l'historique complet des dossiers
- Audit de contrats complexes — extraction et comparaison de clauses sur des milliers de pages
- Recherche de précédents : « Retrouve tous les jugements des dix dernières années où cette clause a été annulée »

7.2 Santé & Recherche Médicale

La protection des données de santé (HDS/RGPD) interdit formellement l'usage d'IA connectées à des serveurs externes. Aurora offre :

- Analyse transversale de comptes-rendus d'hospitalisation anonymisés
- Assistance au diagnostic en circuit fermé sur la littérature médicale locale
- Alertes sur interactions médicamenteuses rares via bases de pharmacovigilance privées

7.3 Recherche Scientifique & Ingénierie

- Synthèse transversale de brevets — cartographie des technologies existantes
- Analyse contradictoire entre études scientifiques
- Traitement de documentation industrielle volumineuse

7.4 Résilience Territoriale — Île de La Réunion

L'architecture locale d'Aurora présente un avantage stratégique particulier pour les territoires ultramarins. La Réunion est exposée à un risque structurel : les coupures de câbles sous-marins qui connectent l'île au réseau internet mondial. Aurora Infinity est totalement imperméable à ces incidents — il fonctionne en autonomie complète, maintenant la continuité des opérations quelle que soit la connectivité externe.

8. Feuille de Route R&D

Les phases de développement actuelles et planifiées :

Phase	Objectifs
Phase Actuelle — Validation V5.4	Opérationnel : Oracle RAG, Pipeline vectoriel, Réseau neuronal 3D, Calcul symbolique/spectral, Archivage Rhizome, Élagage synaptique
Phase 2 — Sécurité & Chiffrement	Chiffrement AES-256 du cerveau synaptique, Télémétrie anti-vol, Traçabilité utilisateur complète
Phase 3 — Omni-Format	Extension du pipeline : tableurs Excel/CSV, présentations PPTX, archives EML, bases XML/JSON
Phase 4 — Interface Graphique (GUI)	Transition CLI vers interface graphique moderne — accessibilité professionnels non techniciens
Phase 5 — Pipeline Automatique	File-Watcher : scan automatique du dossier d'entrée, vectorisation autonome des nouveaux fichiers
Phase 6 — Laboratoire Réseau	Architecture client/serveur locale — validation de l'étanchéité réseau et de la diode tampon
Phase 7 — Crash-Test Longue Distance	Test stress réseau Réunion ↔ Métropole (>9 000 km) — mesure de latence câbles sous-marins

9. Modèle Économique Projeté (Post-R&D)

La commercialisation interviendra exclusivement après achèvement et validation des phases de R&D. Le modèle HaaS (Hardware as a Service) déploie une infrastructure cognitive souveraine chez le client :

Forfait	Cible
EXPLORER — 290€/mois	Créateurs / Développeurs Indépendants
ESSENTIAL — 590€/mois	Cabinets juridiques / Cliniques
HORIZON — 950€/mois	PME / Architectes / R&D
ADD-ONS — +150€/mois	Tout client existant

10. Conclusion

« Nous ne cherchons plus l'information. Nous l'habitons, nous la traitons, et nous la faisons travailler pour nous. Ce n'est pas seulement du code. C'est l'avenir du savoir. »

Aurora V5.4 n'est pas une destination — c'est une fondation. Ce que ce livre blanc documente est la preuve irréfutable qu'une IA souveraine, puissante et frugale est techniquement réalisable dès aujourd'hui, sur du matériel grand public, sans dépendance cloud.

Chaque ligne de code, chaque connexion neuronale, chaque vecteur stocké dans la base FAISS reflète une maîtrise croissante du flux d'information. Aurora ne se contente plus de répondre aux

questions — il anticipe les besoins de réflexion. Le système a dépassé le stade de l'outil pour entrer dans celui de l'extension cognitive.

Le futur est local. Le futur est souverain. Et sa recherche est désormais opérationnelle.

Carpentier Bertrand — C.B.R. | Île de La Réunion | Juin 2026